

# Groonga ではじめる全文検索

版 発行

## 第 1 章

# MySQL で作る全文検索システム

Groonga は様々なソフトウェアに組み込み、全文検索機能を提供することができます。その一つ、MySQL に組み込むための Mroonga を使って、全文検索システムを作ってみましょう。

### 1.1 Mroonga の概要

Mroonga は、MySQL のストレージエンジンの一つです<sup>\*1</sup>。MySQL のストレージエンジンには MyISAM や InnoDB などがあり、聞いたことがある人も多いでしょう。それぞれにパフォーマンスや対障害性などに特徴があり、テーブルごとに使い分けることができます。

その一つとして Mroonga は、Groonga を組み込んで、高速かつ多機能な全文検索を可能にしたストレージエンジンです。これを MySQL に組み込んで使うことで、SQL を使って全文検索を行えるようになります。

Mroonga を全文検索システムの本番環境で使うには、公式マニュアルのインストールのページを参照してください。ここでは、本書で試す目的で、簡易に環境を準備する方法を紹介します。

### 1.2 Mroonga の環境の準備

本書では、MySQL 及びその他の環境の準備に Docker を使います。

以後、PHP と MySQL、Mroonga を使って PDF 文書の全文検索システムを作成していきますが、普段使っているシステムにインストール済みの物を使うと、バージョンが異なって本書の内容が当てはまらなかったり、また、将来別件で異なるバージョンをインストールしたい場合などに手間が増えてしまいます。設定ファイルの競合も問題になるかも知れません。Docker を使うと、システムの方に影響を与えずに、本書で必要なバージョンのソフトウェアを揃えることができます。不要になった場合には削除することも簡単で、その場合もシステムの方には影響を及ぼしません。

---

<sup>\*1</sup> MySQL から派生した MariaDB というデータベースシステムでも使用できます。最新の MariaDB では始めから Mroonga が組み込まれています。

## Docker のインストール

(後で書く)

## Docker コンテナの起動

本書用に必要なソフトウェアをインストールした Docker イメージを作成してあります。ターミナルで上の `docker run` を実行したディレクトリーに移動し、以下のコマンドを実行してください。

リスト 1.1 Docker イメージの取得とコンテナの起動

```
% cd path/to/project
% docker run --detach --name=pdfsearch --publish=8080:80 \
  --volume=$PWD:/var/lib/pdfsearch kitaitimakoto/grnbook-mroonga
```

`docker run` コマンドにより、以下の三つのことが行われます。

1. インターネット経由の Docker イメージの取得 (もしシステム上に存在しない場合)
2. 取得した Docker イメージを元にした Docker コンテナの作成
3. 作成した Docker コンテナの起動

Docker イメージの取得とコンテナの作成は一度行えば充分なので、コンテナの二度目以降の起動には別のコマンドを使用します。

1zwDocker コンテナの起動

```
% docker start pdfsearch
```

1zwDocker コンテナの停止

```
% docker stop pdfsearch
```

コンテナの操作に使用している `pdfsearch` という名前は、リスト 2.1 における `name` オプションで指定した物を使用しています。`docker run` 実行時に異なる名前を指定した場合は、そちらを使いましょう。(name をつけ忘れた時は `docker ps` で探して消すが、説明いる?)

もし、二度目も `docker run` コマンドを使用してしまうと、新たに別のコンテナを作成してしまいます。MySQL のデータ等は引き継がれませんし、同じ目的のコンテナが二つ以上あると混乱の元ですので、通常は一つになるようにしておきましょう。

## 動作確認

Docker コンテナが実際に動作していることを確認しましょう。このイメージには PHP が含まれているので、`docker run` を実行したディレクトリーで以下のようなファイルを作成することで動作確認ができます。

リスト 1.2 info.php

```
<?php
phpinfo();
```

ブラウザで <http://localhost:8080/info.php> にアクセスしてください。以下のように PHP の情報が表示されれば、環境の準備は成功しています。( Docker Toolbox 使っている場合は localhost じゃなさそう )

PHP Version 5.6.17-0+deb8u1	
System	Linux 33ae784095d0 4.2.0
Build Date	Jan 13 2016 09:09:23
Server API	Built-in HTTP server
Virtual Directory Support	disabled
Configuration File (php.ini) Path	/etc/php5/cli
Loaded Configuration File	/etc/php5/cli/php.ini
Scan this dir for additional .ini files	/etc/php5/cli/conf.d
Additional .ini files parsed	/etc/php5/cli/conf.d/05-o /etc/php5/cli/conf.d/20-r
PHP API	20131106
PHP Extension	20131226
Zend Extension	220131226
Zend Extension Build	API220131226,NTS
PHP Extension Build	API20131226,NTS
Debug Build	no
Thread Safety	disabled
Zend Signal Handling	disabled
Zend Memory Manager	disabled

図 1.1 phpinfo() の実行結果

「Not Found」の画面が表示されてしまう場合は、どこかで間違えてしまったようです。これまでの手順を見ながらやり直してみてください。

`docker run` をやり直すには、以下のコマンドを実行して一旦 Docker コンテナを停止し、削除する必要があります。

#### 1zwDocker コンテナの停止と削除

```
% docker stop pdfsearch
% docker rm pdfsearch
```

ありがちな間違いとして、Docker コンテナとの共有ディレクトリーの指定ミスがあります。Docker コンテナとホストマシンは、`docker run` コマンドの `volume (v)` オプションで指定したディレクトリーを共有します。上の例では `$PWD:/var/lib/pdfsearch` を指定しています。コロンの左側がホストマシンのディレクトリー、右側がコンテナ内のディレクトリーです。`$PWD` は (`docker run` を実行した) 現在のディレクトリーを意味しますので、そこと別のディレクトリーにファイルを置いた場合は、コンテナ内の PHP が認識できません。事前にプロジェクトのディレクトリーに移動してから実行するようにしましょう (コンテナ内は `/var/lib/pdfsearch` がドキュメントルートとなるよう設定されており、こちらは常にこの値で大丈夫です)。

## 1.3 作成する全文検索システムの概要

それでは、PHP と Mroonga を使って、全文検索システムを作っていきます。以下のようなシステムを作ることにします。

### 概要

登録済みの PDF ファイルを全文検索するシステムである

### できること

検索対象となる文書をウェブ UI で登録することができる

ウェブ UI 上のテキストフィールドを使って検索することができる

### 実装方針

ウェブ UI は PHP を使用して作成する

全文検索用のデータは MySQL に格納する

PDF からテキストを抜き出す処理は本書では扱わない (Docker イメージ付属のツールを使う)

## 1.4 データベースの作成

まず、PHP を使って、MySQL にデータベースを作成します。作成の手順は通常の MySQL でデータベース作成と同様です。Docker コンテナ内では既に MySQL が動作しており、root ユーザーでパスワード無しでログインできます。

ソースコードは以下のようになります。<sup>\*2</sup>

<sup>\*2</sup> 限定された状況での一度きりの処理のため、褒められない書き方をしている箇所もあります。実際のアプリケーションで使用する場合には、フレームワークなどのやり方に則った適切な方法でデータベースを操作してください。

## リスト 1.3 create-database.php

```
<?php
define('DBNAME', 'pdfsearch');

$dbh = new PDO('mysql:host=localhost;charset=utf8', 'root', '');

if ($_SERVER['REQUEST_METHOD'] === 'POST') {
    $result = $dbh->exec('CREATE DATABASE ' . DBNAME);

    header("Location: ␣{$_SERVER['REQUEST_URI']}");
}

$result = $dbh->query('SHOW DATABASES')->fetchAll();
$databases = array_map(function($row) {
    return $row[0];
}, $result);
?>
<!doctype html>
<html>
<head>
<title>データベースの作成</title>
</head>
<body>
<h1>データベースの作成</h1>
<?php if (! (in_array(DBNAME, $databases))) : ?>
<form method="post">
    <input type="submit" value="pdfsearchデータベースの作成">
</form>
<?php endif; ?>
<h2>現在のデータベース一覧</h2>
<ul>
<?php foreach ($databases as $database) : ?>
    <li><?php echo htmlspecialchars($database, ENT_QUOTES, 'UTF-8'); ?></li>
<?php endforeach; ?>
</ul>
</body>
</html>
```

通常の MySQL に於けるデータベースと全く同じ手順でデータベースを作成していることが分かります。Mroonga を使う場合にも、データベースの作成には特別なことはありません。

うまくできたら、<http://localhost:8080/create-database.php> を表示して、実際に画面上のボタンを押してデータベースを作成してみましょう。「現在のデータベース一覧」に「pdfsearch」というデータベースが加わるはずです。

## コラム: PHP のデバッグ

PHP が期待通りに動作しない場合や画面が真っ白になって何が悪いかわからない場合は、`docker logs` コマンドでログを確認することができます。

## リスト 1.4 docker logs で PHP のログを確認

```
% docker log pdfsearch
13.03.2016 09:41:25 INFO -- [web:php] switch :starting [:unmonitored => :starting] (
reason: monitor by user)
160313 09:41:26 mysqld_safe Can't log to error log and syslog at the same time. Remove
all --log-error configuration options for --syslog to take effect.
160313 09:41:26 mysqld_safe Logging to '/var/log/mysql/error.log'.
160313 09:41:27 mysqld_safe Starting mysqld daemon with databases from /var/lib/mysql
[Sun Mar 13 09:41:54 2016] 172.17.0.1:58804 [200]: /create-database.php
[Sun Mar 13 09:41:55 2016] 172.17.0.1:58808 [404]: /favicon.ico - No such file or
directory
[Sun Mar 13 09:42:01 2016] PHP Parse error: syntax error, unexpected '$databases' (
T_VARIABLE) in /var/lib/pdfsearch/create-database.php on line 14
[Sun Mar 13 09:42:01 2016] 172.17.0.1:58812 [500]: /create-database.php - syntax error,
unexpected '$databases' (T_VARIABLE) in /var/lib/pdfsearch/create-database.php on line
14
```

-f オプションを付け

lzw

% docker logs -f pdfsearch

と実行すると、ログが出力する度にそのログが表示されます。Docker コンテナの中では **PHP のビルトインサーバー** が動作しているため、ログの内容もそれに準じます。

また、ブラウザでエラー内容を確認したい場合には、PHP ファイルの冒頭で

lzw

<?php  
ini\_set('display\_errors', 'stdout');

と設定するとよいでしょう。

1.5 テーブルの作成

データベースが出来たので、以下のカラム持つ pdfs テーブル作りましょう。

表 1.1 作成する pdfs テーブル

| カラム     | 内容           | データ型         | 備考           |
|---------|--------------|--------------|--------------|
| path    | システム内のパス（場所） | VARCHAR(255) | 主キー。検索対象ではない |
| title   | PDF 文書のタイトル  | VARCHAR(255) | 検索対象         |
| content | PDF 内のテキスト   | LONGTEXT     | 検索対象         |

やり方はデータベースの作成と同様です。

リスト 1.5 create-table.php

```
<?php
define('DBNAME', 'pdfsearch');
define('TABLE_NAME', 'pdfs');

$dsn = 'mysql:host=localhost;dbname=' . DBNAME . ';charset=utf8';
$dbh = new PDO($dsn, 'root', '');
$table = TABLE_NAME;

if ($_SERVER['REQUEST_METHOD'] === 'POST') {
    $statement = <<<STATEMENT
CREATE TABLE '{$table}' (
    path    VARCHAR(255) PRIMARY KEY,
    title   VARCHAR(255),
    content LONGTEXT,
    FULLTEXT INDEX (title),
    FULLTEXT INDEX (content)
) ENGINE = Mroonga DEFAULT CHARSET utf8;
STATEMENT;
    $dbh->exec($statement);

    header("Location: ␣{$_SERVER['REQUEST_URI']}");
}

$result = $dbh->query('SHOW ␣TABLES')->fetchAll();
$tables = array_map(function($row) {
    return $row[0];
}, $result);

?>
<!doctype html>
<html>
```

```

<head>
  <title>テーブルの作成</title>
</head>
<body>
  <h1>テーブルの作成</h1>
  <?php if (! (in_array(TABLE_NAME, $tables))) : ?>
    <form method="post">
      <input type="submit" value="pdfsテーブルの作成">
    </form>
  <?php endif; ?>
  <h2>現在のテーブル一覧</h2>
  <ul>
    <?php foreach ($tables as $table): ?>
      <li><?php echo htmlspecialchars($table, ENT_QUOTES, 'UTF-8') ?></li>
    <?php endforeach; ?>
  </ul>
</body>
</html>

```

http://localhost:8080/create-table.php にアクセスして pdfs テーブルを作成してみましょう。事前に pdfsearch テーブルを作っておかないとエラーになるので注意してください。

データベース作成時と違って、Mroonga を使ったテーブルを作る時にはいくつか注意点があります。

一番大事なのは、CREATE TABLE 文の最後に、ストレージエンジンとして Mroonga を指定することです。

lzw

```

CREATE TABLE (
  ...
) ENGINE = Mroonga DEFAULT CHARSET utf8;

```

普段は InnoDB や MyISAM を指定しているところを切り替えるだけなので、難しいことはないでしょう。

次に、インデックスの作成方法が InnoDB などと異なります。PDF のタイトルや内容を完全一致で検索することはまずないでしょうから、通常のインデックスは貼る必要がありません。代わりに、全文検索のための特別なインデックスを作る、FULLTEXT INDEX 構文を使用します。これは、MySQL に元々備わっている、全文検索機能のための構文です。Mroonga でも用途は同じなので、全く同じ構文で使用できます。

それ以外は、通常の MySQL 使い方と同じです。主キーにはパスといった意味のある物ではなく、ただレコードを識別するためだけのサロゲートキーを使う人もいることでしょう。それでも構いません。